

深度學習期末報告


使用 **Faster R-CNN** 對胸部 X 光影像進行潛在疾病之偵測及標註

I. 問題描述與研究目的

胸部 X 光影像已成為診斷肺部及胸腔等疾病的重要工具。然而，人工判讀影像存在效率低下及易受主觀因素影響的問題。因此，本研究的目的是利用深度學習方法，預測胸部 X 光影像中的異常部位，並針對各異常部位標註可能的疾病（如圖一），希望透過深度學習方法建立有效偵測異常區域及疾病的預測模型，提升醫學影像分析的效率與準確性，並降低人工判讀成本。

因而本研究之重要性為：

- 提高診斷準確率，減輕醫師的負擔。
- 為早期發現和治療肺部疾病提供技術支持。
- 發展可拓展至醫學影像物件偵測之人工智慧工具。



圖一、預測之 X 光影像及其異常部位

II. 資料來源與背景


本次研究資料來自高雄義大醫院，共計 451 筆已標註的資料，以及 113 筆測試資料。已標註的影像包含多類疾病的標籤及位置框 (bounding boxes) 的胸部 X 光影像，其中異常疾病包括：主動脈硬鈣化 (aortic_atherosclerosis_calcification)、主動脈彎曲 (aortic_curvature)、肺野浸

潤增加 (lung_field_infiltration)、胸椎退化性關節病變 (degenerative_joint_disease_of_the_thoracic_spine)、脊椎側彎 (scoliosis)、肺尖肋膜增厚 (intercostal_pleural_thickening)、心臟肥大 (cardiac_hypertrophy)

III. 分析流程

a. 資料前處理

在資料前處理的過程中，資料被分為兩大部分：其一為影像檔案，包括 X 光照片及對應的標註位置圖片檔；其二為影像的對應資訊 csv 檔案。為確保後續處理的高效性與準確性，除了對資料進行預覽及檢視每個類別的第一張影像和對應的疾病標註外（圖二），還進行了影像正規化處理（圖三）、提取影像中異常區域的位置信息、分割已標註的資料為訓練集及驗證集並進行數據之 COCO 格式轉換。



圖二、X 光影像及疾病標註

TDR02_20161209_161439



圖三、不同轉換後之 x 光影像圖

對於 X 光影像正規化處理的部分，進行了強度對數變換（log-transformation）與對比度調整，並利用 DICOM 文件中的 Window Width 和 Window Center 資訊，還原影像的原始強度值，並進一步提升影像的對比度，其中，強度對數變換可以有效解決 X 光影像強度分布範圍過大的問題，提升影像中異常結構的可視性。而對比度調整則有助於強化重要結構的區別，使病變部位更加突出，從而為模型提供更具辨識度的輸入數據。經過這些處理後，影像進一步正規化到 0 至 1 的範圍內，以確保輸入模型的數據標準化，有助於提升模型訓練的穩定性。

在標籤與框選處理的部分，提取影像中異常區域的位置信息，將標註的異常區域轉換為 bounding box 作為模型的輸入。對於正常影像，則生成空 bounding box (0, 0, 0, 0)。

同時，為了後續驗證模型訓練結果，以挑選最適當的模型，所有已標註的數據按照影像 ID 進行多標籤分割，劃分為訓練集與驗證集（圖四），確保多標籤影像的完整性和合理性。



圖四、訓練資料與驗證資料各疾病類別分佈圖

最後，將處理後的訓練與驗證數據轉換為 COCO 格式，以便與深度學習框架


(如 Faster R-CNN) 的標準輸入格式兼容。

b. 模型介紹與訓練結果


本研究使用了基於 ResNet-50 (圖五) 的 Faster R-CNN (圖六) 模型作為物件偵測的主要框架。該模型結合了 ResNet-50 特徵提取網絡和特徵金字塔網絡 (FPN)，以提升對多尺度物件的檢測能力。此外，模型中的分類頭部進行了修改，將原始的 COCO 預訓練權重替換為符合研究資料集所需的分類數量，並加入新的分類層進行微調。

模型的主要特點包括：

1. ResNet-50 作為骨幹網絡：高效提取影像特徵。
2. 特徵金字塔網絡 (FPN)：提升多尺度特徵的檢測效果。
3. RPN (Region Proposal Network)：生成高質量的候選區域進行進一步分類與邊界框回歸。
4. 端到端訓練：對分類、邊界框回歸及 RPN 損失進行聯合優化。



圖五、ResNet-50 模型架構




圖六、Faster R-CNN 架構

在模型訓練過程中使用訓練集進行端到端學習(batch_size = 4, epochs = 20)，並在驗證集上評估其性能，其中本模型訓練過程中並未使用資料增強技巧來提升模型的泛化能力，並在優化器的部分採用帶 Nesterov 動量的隨機梯度下降 (SGD)，學習率設為 $1e-3$ 、momentum 為 0.9，由於資料筆數不多，因此沒有使用權重衰減 (weight_decay) 以防止過擬合，將 weight_decay 設為 0。同時經過測試，利用調度器 (scheduler)動態調整學習率的效果較差，因而未使用 scheduler。

最後在模型評估的部分，除了使用 mAP 衡量模型預測結果外，同時也總和四種損失計算模型總損失，包含分類損失、邊界框回歸損失、RPN 相關損失 (物件性損失和邊界框回歸損失)

以下為模型的訓練與驗證結果（圖七）：




圖七、模型的訓練與驗證結果

1. mAP50 (mean Average Precision at IoU=0.5) :
 - (1). 訓練集 mAP50 隨 epoch 增加而穩步提升，最終達到 0.65 左右。
 - (2). 驗證集 mAP50 表現穩定，最終約為 0.48，表明模型對未知資料具有一定的泛化能力。
2. 總損失 (Total Loss) :

- (1). 訓練損失從初始的 0.3 快速下降至 0.1 以下，說明模型學習了有效特徵。
 - (2). 驗證損失收斂到 0.15 左右，略高於訓練損失，可能存在資料過擬合的問題模型仍有進一步優化空間。
3. 分類損失 (Classifier Loss) :
- (1). 訓練與驗證分類損失均呈現穩定下降的趨勢，驗證損失略高於訓練損失，但絕對數值偏小，顯示模型對異常區域的分類表現良好。
4. 邊界框回歸損失 (Box Regression Loss) :
- (1). 訓練損失顯著降低，最終穩定於 0.04 左右，驗證損失略高，約為 0.05，顯示模型對異常區域位置的預測能力較準確。
5. RPN 相關損失 :
- (1). RPN 物件性損失 (Objectness Loss) 和 RPN 邊界框回歸損失均隨訓練進行穩步下降，驗證損失趨勢與訓練損失一致，但稍高。

c. 模型解釋與視覺化

- EigenCAM 分析 (圖八左) : 在檢測 cardiac_hypertrophy (心臟肥大) 時，模型主要集中在心臟周圍的區域，表明模型能有效識別心臟區域的結構特徵。此外，對於 lung_field_infiltration (肺野浸潤增加)，模型的注意力分佈於整個肺部的下半區域，這與臨床診斷中通常觀察到的病變位置一致。這些可視化結果表明，模型在分類和定位異常結構時，能夠捕捉到與疾病相關的重要區域。
- AblationCAM 分析 (圖八右) : 在檢測 aortic_curvature (主動脈彎曲) 時，AblationCAM 顯示模型的注意力集中於主動脈的形狀特徵，說明模型對於主動脈幾何結構的變化具有敏銳的辨識力。同樣，對於 scoliosis (脊椎側彎)，模型的焦點集中在脊柱區域，這與該疾病的病理特徵完全吻合。這進一步驗證了模型在處理不同類型病變時的學習靈活性與準確性。
- 整體而言 EigenCAM 展示了模型整體學習模式，而 AblationCAM 則提供了模型對關鍵特徵的細緻理解及學習過程




圖八、模型訓練過程之視覺化

d. 模型預測過程與框選擇策略

1. 模型輸出與初步篩選：模型預測的輸出包括每個候選框的邊界座標、對應的類別標籤、類別名稱，以及置信分數（scores）。首先，根據置信分數（scores）進行初步篩選，僅保留置信分數高於閾值（0.1）的框，以確保僅處理高可信度的預測。
2. 小框去除：在初步篩選後，針對所有候選框進行進一步的形狀檢查，去除寬度或高度過小的框（例如，寬度或高度小於 2 像素的框）。這是為了避免模型生成無效或幾何尺寸過小的框，提升預測結果的有效性。
3. 使用非極大值抑制（NMS）去除冗餘框：對每個類別的框，根據框的置信分數進行排序，優先處理得分最高的框，計算當前最高得分框與

其他框的交並比 (IoU) 如果 IoU 超過閾值 ($iou_threshold=0.2$)，則認為這些框存在高度重疊，僅保留最高得分的框，其餘框將被移除。透過此方法可確保了每一類別內僅保留關鍵的、高置信的框，最大程度地去除了重疊或冗餘框。

4. 可視化與結果輸出 (圖九)



IV. 結論與未來方向

本研究雖成功建立了基於 **Faster R-CNN** 的胸部異常檢測模型，但在初步檢視測試集資料時發現，許多影像存在不同程度的左右傾斜及水平位移現象。這些變化在影像中會對模型的特徵提取與異常區域的定位造成一定影響，從而可能導致預測結果的準確性下降，例如脊椎側彎可能因影像角度偏移而預測錯誤。

1. 研究限制

(1). 測試集影像的傾斜與位移問題：由於部分測試集影像在拍攝過程中存

在左右傾斜或水平位移，這些變化未能充分體現在訓練集的資料中，導致模型在處理此類影像時可能無法有效適應。

- (2). 資料多樣性及樣本大小不足：雖然訓練集資料包含了不同類別的標註，但由於缺乏旋轉或位移的擴充資料，模型的泛化能力在應對未知變化時仍存在一定局限性。

2. 未來改善方向

- (1). 資料增強技術的應用：未來可在訓練階段引入資料增強技術，對訓練影像進行隨機旋轉、水平位移等操作，生成包含這些變化的標註資料。這不僅能提升模型的適應能力，還能幫助模型學習到對不同角度與位移的魯棒性特徵。
- (2). 對抗式資料生成：可嘗試應用生成對抗網絡 (GAN)，生成更具多樣性且包含實際偏移與旋轉特徵的合成影像，以進一步提升模型對特殊情況的處理能力。
- (3). 自適應模型調整：引入旋轉不變性與平移不變性的特徵提取方法，進一步提升模型對異常區域的敏感度。例如，考慮在模型中加入 CNN 特徵提取層的旋轉不變性模塊。

未來的改進方向將集中在提升資料的多樣性與標註的精準度，並優化模型的結構，以更好地適應臨床應用中可能出現的影像變化場景，進一步提高胸部異常檢測的準確率和穩健性。